

FIAP – FACULDADE DE INFORMÁTICA E ADMINISTRAÇÃO PAULISTA
Engenharia de Computação

VisionEPI

Solução final de segurança industrial com IA: YOLO treinado no domínio e
LLM multimodal como segunda opinião

Challenge 2026 – Metaindústria (FIAP × SPI Integração)

Sprint 4 – Solução Final

Inteligência Artificial e Computacional

São Paulo

2026

VisionEPI

Solução final de segurança industrial com IA

Nome	RM
Pedro Gonçalves	557936
Lucas Baraldi	555407
Lucas Zolla	557952
Vitor Pantarotto	554961

Curso: Engenharia de Computação

Ano: 3º ano – 2026

Turma: 3ECR

Disciplina: Inteligência Artificial e Computacional

Professor: Prof. José Maia Neto

Repositório do projeto: https://github.com/bolla-X/Challenge_5550

SUMÁRIO

1 Introdução e problema.....	5
2 Evolução da solução ao longo das Sprints.....	5
3 Arquitetura final da solução.....	6
3.1 Funcionamento do fluxo da aplicação.....	7
4 Tecnologias e modelos utilizados.....	8
4.1 Justificativa: por que YOLO e LLM.....	8
4.2 O modelo treinado.....	8
5 Principais decisões do projeto.....	9
6 Testes realizados.....	10
6.1 Método de avaliação.....	10
6.2 O conjunto de teste, olhado de perto.....	10
6.3 Testes do sistema em execução.....	10
7 Principais resultados.....	12
7.1 A camada LLM.....	15
8 Erros e limitações encontradas.....	15
9 Possíveis melhorias e próximos passos.....	17
10 Conclusão.....	17
Referências.....	17

LISTA DE FIGURAS E TABELAS

Figura 1 – Achado da Sprint 3: dois trabalhadores de capacete, dois alertas de "capacete ausente"

Figura 2 – Arquitetura final do VisionEPI (Sprint 4)

Figura 3 – Painel do Supervisor com o peso novo: conformidade por pessoa e o estado "visto sem o EPI"

Figura 4 – Tela do Operador em execução, com máscara indicada como indisponível no modelo atual

Figura 5 – Precisão e revocação do alerta, Sprint 3 × Sprint 4, com IC 95%

Figura 6 – Sprint 3 na imagem image1037 (esquerda: anotação; direita: sistema)

Figura 7 – Sprint 4 na mesma imagem: nenhum alerta de capacete ou colete

Figura 8 – Erro de anotação: colete refletivo anotado como ausente; o sistema acerta

Tabela 1 – Evolução do VisionEPI por sprint

Tabela 2 – Sequência de processamento de um quadro

Tabela 3 – Principais tecnologias

Tabela 4 – Comparação entre as duas camadas

Tabela 5 – Seleção da configuração na validação (143 imagens, política ausência, conf 0,35)

Tabela 6 – Resultado no conjunto de teste (236 pessoas, política ausência)

Tabela 7 – Alertas falsos por subconjunto do teste (política ausência)

Tabela 8 – Desempenho do pipeline completo (CPU de 2 núcleos, 240 quadros)

Tabela 9 – Respostas reais do Gemini 3.6 Flash (Sprint 3)

Tabela 10 – Revisão dos erros do peso novo

1 Introdução e problema

O modelo tradicional de segurança do trabalho é reativo: inspeções periódicas, checklists preenchidos à mão e investigação depois do acidente. O **VisionEPI** propõe o oposto — monitoramento contínuo de câmeras comuns (IP/RTSP ou USB) por visão computacional, com alerta em tempo real sobre **pessoa sem Equipamento de Proteção Individual** (capacete, colete, luvas, óculos, calçado), **queda ou postura de risco** e **presença em área de risco**, cada alerta acompanhado da foto do momento. A base normativa é a NR-6 (EPI) e a NR-18 (construção).

O erro que importa não é simétrico. Um **alerta falso** — acusar quem está de EPI — gasta a atenção do supervisor e, repetido, ensina a equipe a ignorar o painel. Uma **violação sem alerta** é o acidente que o sistema existe para evitar. Por isso esta sprint mede o sistema pelo alerta, pessoa por pessoa: a **precisão** (dos alertas emitidos, quantos estão certos) e a **revocação** (das violações reais, quantas geraram alerta).

A Sprint 3 terminou com dois achados: (i) o detector YOLO usado até então (Vyra) atribuía confiança de 0,14 a 0,26 a capacetes visíveis a olho nu, o que gerava alertas críticos de "sem capacete" sobre trabalhadores de capacete (Figura 1); e (ii) as três cenas usadas na avaliação sustentavam a existência do comportamento, mas não uma afirmação de acurácia. A Sprint 4 parte desses dois pontos: corrigir a causa no detector e medir em escala.

Figura 1 – Achado da Sprint 3: dois trabalhadores de capacete, dois alertas de "capacete ausente"



Fonte: Elaborado pelo grupo sobre foto de Grand Canyon NPS (CC BY 2.0), entrega da Sprint 3.

2 Evolução da solução ao longo das Sprints

Cada sprint nasceu de uma medição feita na anterior. A Tabela 1 resume o que entrou em cada etapa e qual achado motivou a seguinte.

Tabela 1 – Evolução do VisionEPI por sprint

Sprint	O que entrou	O que a medição mostrou
1 (jul/26)	Protótipo: detecção de EPI em vídeo e primeira interface	—
2 (ago/26)	YOLOv8 Vyra (14 classes) + YOLOv8n COCO para pessoa; MediaPipe Pose por pessoa; rastreador IoU; associação EPI ↔ pessoa; multi-câmera; React + Socket.IO; login com três papéis	—
3 (set/26)	LLM multimodal (Gemini 3.6 Flash) como segunda opinião assíncrona; prompts v1 e v2; RTSP resiliente; benchmarks	Classe Person do Vyra não detecta ninguém fora do dataset dele (0 detecções em 36 combinações) → segundo modelo obrigatório, -20% de FPS; capacete fraco no modelo, não na resolução; alerta falso na cena segura; o prompt v2 corrige esse caso; 16 a 38 s por chamada
4 (set/26)	Peso próprio treinado no domínio; classes negativas e o estado "não verificado"; segundo gatilho do LLM; avaliação por pessoa em conjunto anotado	Precisão do alerta de capacete 0,39 → 0,85; revocação do colete 0,79 → 0,69 (Seção 7)

Fonte: Elaborado pelo grupo.


3 Arquitetura final da solução

A solução final combina **YOLO** e **LLM multimodal**, cada um em um plano diferente do sistema (Figura 2).

Figura 2 – Arquitetura final do VisionEPI (Sprint 4)

VisionEPI — arquitetura final (Sprint 4)

YOLO treinado no domínio + LLM multimodal como segunda opinião assíncrona. Selo verde = o que mudou na Sprint 4.



Fonte: Elaborado pelo grupo.

- **Caminho do frame (síncrono, uma thread por câmera):** VideoStream → YOLOv8n VisionEPI (um único peso: pessoa, cinco EPIs e cinco classes negativas) → PersonTracker (identidade estável por IoU) → PersonComplianceMatcher (EPI associado à pessoa por geometria, com três leituras por EPI) → MediaPipe Pose por pessoa → RuleEngine → AlertStateService (histerese: cria após 3 detecções, resolve após 5) → JPEG codificado uma única vez.
- **Segunda opinião (assíncrona e descartável):** dois gatilhos — alerta criado, ou capacete/colete "não verificado" por 3 detecções — entregam o JPEG já codificado ao ServicoDeRiscoLLM. O envio custa 9 a 13 µs; há debounce de 15 s, no máximo uma chamada em voo por câmera e descarte em vez de fila. A resposta do Gemini é validada por schema e vai para um campo separado (segunda_opiniao). O LLM **não cria, não resolve e não suprime alerta**.
- **Estado e interface:** SQLite/PostgreSQL com migrações Alembic; Flask com REST e Socket.IO, escopo por câmera; SPA React com os papéis Operador, Técnico e Supervisor.

3.1 Funcionamento do fluxo da aplicação

Tabela 2 – Sequência de processamento de um quadro

Etapa	O que acontece
1. Aquisição	O VideoStream lê o quadro mais recente da câmera (RTSP, USB ou arquivo), descarta quadros atrasados em fonte de rede e, se a fonte morre, assume o modo fixture sinalizado na tela.
2. Detecção	Um único YOLOv8n (38 ms p50 em CPU) localiza pessoas, EPIs e ausências explícitas (cabeça sem capacete, torso sem colete).
3. Identidade	O rastreador por IoU mantém o id de cada pessoa entre quadros.
4. Associação	Cada caixa de EPI — positiva ou negativa — é atribuída a no máximo uma pessoa, pela faixa vertical esperada e pelo alinhamento horizontal.
5. Estado	Por pessoa e EPI: detectado, visto sem ou não detectado; a política configurada decide se "não detectado" é violação.
6. Pose	O MediaPipe estima 33 pontos no recorte de cada pessoa para queda e postura.
7. Regras e histerese	O RuleEngine gera candidatos a alerta; o AlertStateService só cria após 3 detecções e resolve após 5.
8. Resposta	Alerta gravado com foto, emitido ao painel via WebSocket; o operador marca "avisei o colaborador" ou "falso positivo".
9. Segunda opinião	Fora da thread: o LLM analisa a imagem e devolve nível de risco, EPIs ausentes, justificativa e ação recomendada.

Fonte: Elaborado pelo grupo.

4 Tecnologias e modelos utilizados

Tabela 3 – Principais tecnologias

Camada	Tecnologia
Detecção de pessoa e EPI	Ultralytics YOLOv8n, peso próprio visionepi_cppe_n416.pt (6,2 MB), treinado no Construction-PPE
Postura e queda	Google MediaPipe Pose (recorte por pessoa)
Segunda opinião	Google Gemini 3.6 Flash via google-genai; saída validada com Pydantic
Backend	Python 3.11, Flask, Flask-SocketIO, SQLAlchemy, Alembic, gunicorn
Frontend	React 18 + TypeScript + Vite, Zustand, Socket.IO client
Qualidade	pytest (375 testes), ruff, scripts de benchmark e de avaliação reproduzíveis

Fonte: Elaborado pelo grupo.

4.1 Justificativa: por que YOLO e LLM

Tabela 4 – Comparação entre as duas camadas

Critério	YOLOv8n treinado	Gemini 3.6 Flash
Latência medida	38 ms por quadro (p50)	16 a 38 s por chamada
Cobertura	todo quadro, toda pessoa	uma imagem a cada 15 s ou mais, por câmera
Custo	CPU local, sem rede	cota de API e rede
Conhece o contexto?	não	sim: pondera se o EPI é exigido na atividade
Explica a decisão?	não	sim, em português

Fonte: Elaborado pelo grupo.

Um LLM sozinho não serve para monitoramento contínuo: a mediana de 27 s por chamada congelaria o vídeo e cobriria uma fração mínima dos quadros. Um detector sozinho não sabe que um escritório não exige capacete, nem explica o que viu. A combinação usa o detector para decidir em tempo real e o LLM como segunda opinião fora do caminho do frame.

4.2 O modelo treinado

O peso final é um **YOLOv8n pré-treinado no COCO e ajustado no dataset Construction-PPE** (Ultralytics, licença AGPL-3.0): 1.132 imagens de treino, 143 de validação e 141 de teste, com onze classes — helmet, gloves, vest, boots, goggles, none (torso sem colete, verificado desenhando as anotações), Person, no_helmet, no_goggle, no_gloves e no_boots. O treino teve 40 épocas, imgsz 416, batch 16, seed 0 e modo determinístico, em CPU de dois núcleos, durante 2,6 horas. O peso é versionado no repositório com SHA-256 travado por teste, e o treino é reproduzível por dois comandos (scripts/baixar_dataset.py e scripts/treinar_modelo.py).

A resolução de treino (416) é a mesma em que o pipeline roda. O Vyra havia sido treinado a 640 e era usado a 416 — um dos descasamentos medidos na Sprint 3. No conjunto de teste, o mAP50 das classes positivas é alto (capacete 0,92; colete 0,88; pessoa 0,84), enquanto o das classes negativas é baixo (no_helmet 0,14; no_gloves 0,17), o que pesa na decisão da Seção 5.

5 Principais decisões do projeto

Todas as escolhas abaixo foram feitas no **conjunto de validação**; o de teste só foi usado para relatar o resultado final.

1. **Treinar um peso próprio em vez de ajustar limiar.** A Sprint 3 mostrou que o capacete era fraco no modelo e não na resolução; baixar o limiar traria junto todos os demais falsos positivos.
2. **Um peso só em vez de Vyra + COCO.** A classe Person do peso novo encontrou mais pessoas que o COCO (revocação 0,90 contra 0,84) e o F1 do alerta de capacete foi 0,88 sozinho contra 0,83 com o COCO, pela metade do custo (47 contra 98 ms por imagem) — Tabela 5.
3. **Separar "ausente" de "não visto".** O matcher passou a associar também as classes negativas; cada EPI sai como detectado, visto sem ou não detectado, e o alerta informa ao operador quando a pessoa foi vista sem o EPI.
4. **Política de alerta escolhida por medição.** Com a política "ausência" (não detectado = alerta) o F1 médio de capacete e colete foi 0,83; com a política "evidência" (só alerta quem foi visto sem o EPI) foi 0,62 — ela acerta todos os alertas de capacete que emite, mas só pega 27% das violações. A ausência é o padrão; a evidência fica como opção configurável.
5. **LLM fora do caminho do frame, com invariante.** Mantida da Sprint 3: o LLM informa, não decide. O segundo gatilho ("não verificado" persistente) leva a segunda opinião ao caso em que a Sprint 3 mostrou o LLM agregando valor: distinguir ausente de não visível.
6. **Medir o alerta por pessoa, não só o mAP.** O operador recebe "Pessoa 3 sem capacete"; é esse enunciado que precisa estar certo.

Tabela 5 – Seleção da configuração na validação (143 imagens, política ausência, conf 0,35)

Configuração	Revocação de pessoa	F1 capacete	F1 colete	ms/imagem
Sprint 3: Vyra m + COCO n	0,84	0,60	0,58	358
Peso novo + COCO para pessoa	0,84	0,83	0,79	98
Peso novo, um único modelo	0,90	0,88	0,79	47

Fonte: Elaborado pelo grupo (docs/avaliacao/RESUMO.md).

6 Testes realizados

6.1 Método de avaliação

A avaliação executa **o próprio pipeline do aplicativo** — o mesmo detector e o mesmo matcher, na composição do CameraWorker — sobre imagens com anotação conhecida, e mede o alerta:

- cada pessoa anotada recebe, por EPI, o estado presente, ausente ou não visível (anotação negativa vence a positiva: uma luva e uma mão nua é violação);
- a pessoa prevista é casada com a anotada por $\text{IoU} \geq 0,5$, de forma exclusiva;
- o caso positivo é a pessoa **sem** o EPI; pessoas não visíveis ficam fora da conta, e os alertas emitidos sobre elas são contados à parte;
- a medida é ponta a ponta: pessoa anotada que o detector não encontrou conta como violação perdida;
- o intervalo de confiança de 95% é obtido reamostrando **cenas**, não imagens (400 reamostragens).

As duas políticas são calculadas sobre as mesmas detecções, de modo que a diferença entre elas é só a regra. A régua é coberta por testes unitários (tests/test_avaliacao.py).


6.2 O conjunto de teste, olhado de perto

As 141 imagens de teste (236 pessoas anotadas) foram inspecionadas uma a uma. Duas características mudam a leitura dos números: **47 imagens são quadros da mesma pessoa no mesmo terraço** — no total, 67 imagens estão em sete sequências, e há **81 cenas distintas**; e **todas as 38 violações de capacete estão em cenas não industriais** (escritório, rua, esporte, retrato). Nas 54 cenas industriais distintas não há ninguém sem capacete e há cinco pessoas sem colete. Em canteiro, portanto, o teste mede sobretudo o alerta falso. Por isso os resultados são apresentados também por subconjunto (Tabela 7).

6.3 Testes do sistema em execução

O aplicativo completo foi executado com o peso novo sobre um vídeo montado com dez imagens do conjunto de teste, em situações distintas — equipes conformes, pessoa sem capacete, pessoa sem colete, cenas densas. As capturas foram feitas de forma automatizada (scripts/capturar_evidencias.py) nos três papéis, e o percurso foi gravado em 96 s de vídeo (docs/evidencias/demo_dashboard_sprint4.mp4). A Figura 3 mostra a aba Pessoas, em que o colete da Pessoa 2 aparece como "Ausente (visto sem o EPI)" — o novo estado funcionando no painel.


Figura 3 – Painel do Supervisor com o peso novo: conformidade por pessoa e o estado "visto sem o EPI"



Fonte: Elaborado pelo grupo (captura do sistema em execução; imagem do Construction-PPE).

A Figura 4 mostra a tela do Operador. Ela registra também um erro real, discutido na Seção 8: no vídeo montado, trabalhadores de capacete vermelho, agachados, são acusados de "sem capacete". Essa captura revelou ainda um defeito de interface, corrigido nesta sprint: como o peso novo não tem classe de máscara, o chip de máscara aparecia com check verde por falta de alerta; agora aparece como "indisponível".

Figura 4 – Tela do Operador em execução, com máscara indicada como indisponível no modelo atual



Fonte: Elaborado pelo grupo (captura do sistema em execução; imagem do Construction-PPE).

7 Principais resultados


Tabela 6 – Resultado no conjunto de teste (236 pessoas, política ausência)

Indicador	Sprint 3	Sprint 4
Precisão do alerta "sem capacete" (IC 95%)	0,39 [0,25; 0,57]	0,85 [0,69; 0,98]
Revocação "sem capacete" (IC 95%)	0,87 [0,78; 0,95]	0,92 [0,84; 1,00]
Precisão do alerta "sem colete" (IC 95%)	0,34 [0,18; 0,57]	0,87 [0,76; 0,97]
Revocação "sem colete" (IC 95%)	0,79 [0,66; 0,95]	0,69 [0,53; 0,88]
Alertas de capacete sobre quem está de capacete	52 de 85 alertas	6 de 41 alertas
Inferência por imagem	354 ms	49 ms

Fonte: Elaborado pelo grupo (docs/avaliacao/RESUMO.md).

Os intervalos de confiança da **precisão não se sobrepõem** em nenhum dos dois EPs: a redução do alerta falso não é ruído de amostra. Os de **revocação se sobrepõem**, de modo que nem a melhora do capacete nem a piora do colete são afirmáveis com esta amostra — a piora do colete é, ainda assim, registrada. A Figura 5 mostra as mesmas medidas com seus intervalos.

Figura 5 – Precisão e revocação do alerta, Sprint 3 × Sprint 4, com IC 95%



Fonte: Elaborado pelo grupo.

Tabela 7 – Alertas falsos por subconjunto do teste (política ausência)

Subconjunto	Capacete S3	Capacete S4	Colete S3	Colete S4
Completo (141 imagens)	52 / 153	6 / 153	91 / 150	6 / 150
Sem a sequência do terraço (94)	40 / 108	6 / 108	51 / 105	6 / 105
Uma imagem por cena (81)	30 / 95	6 / 95	50 / 90	6 / 90
Industrial, uma por cena (54)	27 / 92	3 / 92	49 / 89	5 / 89

Fonte: Elaborado pelo grupo. Cada célula: alertas falsos / pessoas que estão com o EPI.

A sequência repetida não infla o resultado do peso novo: nenhum dos seus seis alertas falsos de capacete está nela. Nas cenas industriais distintas, os alertas falsos de capacete caíram de 27 para 3 em 92 pessoas de capacete. Aumentar a resolução não era a saída: o Vyra a 640 px, pelo dobro do custo, sobe a precisão de capacete só de 0,39 para 0,44.

Tabela 8 – Desempenho do pipeline completo (CPU de 2 núcleos, 240 quadros)


Medida	Sprint 3	Sprint 4
YOLO de EPI, p50	197 ms	38 ms
YOLO de pessoa, p50	35 ms	— (mesmo peso)
FPS com detecção a cada quadro	3,42	11,15
FPS com detecção a cada 3 quadros (padrão)	10,13	32,82

Fonte: Elaborado pelo grupo (scripts/bench_pipeline.py).

Com o detector cinco vezes mais barato, o MediaPipe Pose passou a ter a cauda mais cara do quadro — p95 de 116 ms contra 46 ms do YOLO (no p50 o YOLO ainda custa mais, 38 contra 29 ms) —, e é o próximo gargalo.


As Figuras 6 e 7 comparam as duas versões na mesma imagem do teste, com seis pessoas anotadas (seis de colete; cinco de capacete e uma com o capacete não visível). A Sprint 3 emitia cinco alertas falsos de capacete e colete; a Sprint 4, nenhum: as quatro pessoas que detecta recebem os dois EPIs. Duas das seis pessoas não são detectadas, e luvas, óculos e calçado ainda geram alertas.

Figura 6 – Sprint 3 na imagem image1037 (esquerda: anotação; direita: sistema)



Fonte: Elaborado pelo grupo sobre imagem do Construction-PPE (AGPL-3.0).

Figura 7 – Sprint 4 na mesma imagem: nenhum alerta de capacete ou colete



Fonte: Elaborado pelo grupo sobre imagem do Construction-PPE (AGPL-3.0).

7.1 A camada LLM

A camada multimodal foi medida na Sprint 3 com seis chamadas reais (três cenas × duas versões de prompt), congeladas como goldens no repositório e verificadas por 18 testes offline (Tabela 9). O resultado central permanece: na cena segura, o prompt v2 reconhece os dois capacetes que o Vyra não via e distingue EPI ausente de não visível.

Tabela 9 – Respostas reais do Gemini 3.6 Flash (Sprint 3)

Cena	v1: EPIs ausentes (conf.)	v2: EPIs ausentes (conf.)
Segura	luvas, óculos, máscara (0,90)	nenhum (0,80)
Risco	capacete, colete, calçado, luvas (0,95)	capacete, colete (0,85)
Ambígua	luvas, óculos (0,95)	luvas, óculos (0,85)

Fonte: Elaborado pelo grupo (tests/goldens/).

Nesta sprint a camada **não foi re-medida** no novo conjunto: a rede dos dois ambientes de trabalho bloqueia o endpoint da API do Gemini por política da organização, e não havia chave configurada. O script que aplica o prompt v2 às 81 cenas do teste e compara as regras "só YOLO", "só LLM" e "YOLO + LLM nos não verificados" está pronto e testado sem rede (scripts/avaliar_llm_dataset.py).

8 Erros e limitações encontradas


Os 19 erros de capacete e colete do peso novo sobre pessoas que o detector encontrou foram revisados visualmente (docs/avaliacao/auditoria_erros_cppe.json). Os 14 erros de pessoas não detectadas — 3 violações de capacete e 11 de colete — não entram nesta revisão.

Tabela 10 – Revisão dos erros do peso novo

Veredito	Casos	Exemplo
Anotação errada	6	colete laranja refletivo anotado como "sem colete" (Figura 8)
Ambíguo	5	capacete de ciclismo anotado como capacete de segurança
Erro do sistema	8	pessoa pequena ou distante; cena densa; jaqueta de alta visibilidade; pessoa sentada; pessoa sem camisa; jaqueta tomada por colete

Fonte: Elaborado pelo grupo.

Figura 8 – Erro de anotação: colete refletivo anotado como ausente; o sistema acerta



Fonte: Elaborado pelo grupo sobre imagem do Construction-PPE (AGPL-3.0).

Se as seis anotações erradas fossem corrigidas, a revocação do colete iria de 0,69 para 0,76. O número é enviesado a favor do sistema — só os erros foram revisados, não os acertos — e por isso o oficial continua sendo 0,69.

Limitações que este relatório não esconde:

- **Uma única distribuição.** Treino e teste vêm do mesmo dataset público; o peso nunca foi medido nas câmeras da planta, e as três cenas da Sprint 3 não puderam ser baixadas no ambiente desta sprint.
- **O detector não conhece o contexto.** As 38 violações de capacete do teste são de pessoas em escritório, rua ou academia: o sistema acerta "sem capacete", mas ninguém exigiria capacete ali.
- **Classes negativas fracas.** Com mAP50 entre 0,03 e 0,46, a política "evidência" fica com revocação baixa.
- **Máscara saiu do modelo** (o dataset não a contém) e o calçado entrou com precisão de alerta de apenas 0,44.
- **LLM não re-medido nesta sprint**, e o efeito do segundo gatilho sobre a acurácia não tem número.
- **Evidência sobre vídeo montado.** A imagem chega à rede com cerca de 234 px, pouco mais da metade da resolução avaliada, o que explica erros vistos nas capturas e ausentes na avaliação da mesma imagem.

9 Possíveis melhorias e próximos passos

1. Medir o LLM no conjunto anotado (81 chamadas, cerca de 40 minutos no free tier) e decidir, com número, se a regra "evidência + LLM nos não verificados" supera a "ausência".
2. Montar um dataset das câmeras da planta — 200 a 300 quadros, anotados por duas pessoas, com concordância medida —, a única forma de afirmar acurácia no ambiente real.
3. Acrescentar exemplos negativos de obra (cabeça descoberta, torso sem colete), para que a política "evidência" deixe de perder 73% das violações de capacete.
4. Rodar a pose por pessoa rastreada em modo stream: com o detector a 38 ms, o MediaPipe virou o gargalo da cauda (p95 de 116 ms), e o ganho de 2,25× medido na Sprint 3 passou a compensar.
5. Configurar a exigência de EPI por zona (área de obra × escritório), para que o alerta não dispare onde o EPI não é exigido.

10 Conclusão

A solução final do VisionEPI usa cada tecnologia onde ela é forte: um YOLOv8n treinado no domínio decide em tempo real, a 38 ms por quadro, e um LLM multimodal oferece segunda opinião contextual fora do caminho do quadro, sem poder apagar alertas. A principal mudança desta sprint — treinar o detector no domínio e na resolução de operação — elevou a precisão do alerta de capacete de 0,39 para 0,85 e a do colete de 0,34 para 0,87, com intervalos de confiança que não se sobrepõem, e ao mesmo tempo multiplicou o FPS por 3,3. A revocação do colete caiu e está registrada; parte dela se explica por erros da anotação, parte é erro real do sistema. O que falta para afirmar acurácia na planta está listado e tem comando pronto.

Referências

BRASIL. Ministério do Trabalho e Emprego. Norma Regulamentadora n.º 6 (NR-6): Equipamento de Proteção Individual – EPI.

BRASIL. Ministério do Trabalho e Emprego. Norma Regulamentadora n.º 18 (NR-18): Segurança e Saúde no Trabalho na Indústria da Construção.

ULTRALYTICS. YOLOv8 – Documentation. Disponível em: <https://docs.ultralytics.com>. Acesso em: set. 2026.

ULTRALYTICS. Construction-PPE Dataset. Disponível em: <https://docs.ultralytics.com/datasets/detect/construction-ppe/>. Licença AGPL-3.0. Acesso em: set. 2026.

HEXMON. vyra-yolo-ppe-detection (YOLOv8m, 14 classes). Hugging Face, licença CC-BY-4.0. Acesso em: ago. 2026.

LIN, T.-Y. et al. Microsoft COCO: Common Objects in Context. In: European Conference on Computer Vision (ECCV), 2014.

GOOGLE. MediaPipe Pose – solution documentation. Disponível em: <https://github.com/google-ai-edge/mediapipe>. Acesso em: set. 2026.

GOOGLE. Gemini API documentation. Disponível em: <https://ai.google.dev>. Acesso em: set. 2026.

GRUPO VISIONEPI. Challenge_5550 – código-fonte, avaliação e relatórios (docs/SPRINT3.md, docs/SPRINT4.md, docs/BENCH.md). Disponível em: https://github.com/bolla-X/Challenge_5550.