

VisionEPI — Relatório Técnico: Fase 1 — Detecção de EPIs / EPCs

Challenge 2026 — Innovation Challenge CUP — Parceria FIAP x SPI

Engenharia da Computação, 3º ano. Entrega: 04/05/2026.

Equipe

Lucas Baraldi Rodrigues · Lucas Zolla Assis · Pedro Costa Belisário · Vitor Pantarotto de Brito

Professor: Fabio Henrique Pimentel · Mentores SPI: Fernando Marcolina, Wendel de Almeida Passos

1. Escopo desta fase

Detecção em tempo real de, no mínimo, capacete, óculos de proteção, protetor auricular, bota de segurança e colete refletivo, diferenciando **em uso correto**, **em uso incorreto** e **ausente**. Demo funcional em vídeo/stream. Métricas por classe: mAP@0.5, precisão, revocação e F1.

2. O que foi construído

- **Ensemble de dois modelos YOLOv8**, rodando no mesmo quadro: o **Vyra** ([Hexmon/vyra-yolo-ppe-detection](#), pesos prontos, CC BY 4.0) e um modelo **treinado pela própria equipe** no dataset **SH17** (8.099 imagens, 75.994 instâncias, CC BY-NC-SA 4.0 — uso acadêmico), fundidos por IoU (mesmo rótulo + caixa sobreposta = mesma detecção, fica a de maior confiança).
- **7 classes de EPI**: capacete, colete, luvas, óculos, máscara, calçado de segurança e **protetor auricular** — cobrindo os 5 itens mínimos do escopo.
- **Três estados por item** (não dois): "ok", "incorreto" e "ausente". Implementado por geometria: cada EPI tem uma faixa vertical esperada dentro da caixa da pessoa (ex.: capacete no topo, calçado na base). Dentro da faixa = ok. Fora da faixa mas ainda sobre o corpo da pessoa (contenção real da caixa) = uso incorreto (ex.: capacete na mão, não na cabeça). Fora do corpo da pessoa = ausente. Um item incorreto nunca rebaixa quem já está "ok" com outro exemplar do mesmo tipo.
- **Associação geométrica exclusiva EPI<->pessoa**: pontuação por contenção da caixa + proximidade da faixa ideal, resolvendo duas pessoas sobrepostas disputando o mesmo capacete (o de maior pontuação leva; cada EPI serve no máximo uma pessoa).
- **Rastreador de pessoas** (IoU + distância entre centros como plano B): mantém o mesmo número de identificação mesmo quando a pessoa muda de postura ou é parcialmente ocluída.
- **Piso de confiança por classe e filtro geométrico** (EPI só conta se cair dentro de alguma pessoa detectada) — reduz falso positivo de objeto de fundo.
- **Zona de risco configurável por câmera**, desenhada no próprio vídeo.
- **Rotação de câmera**, para câmeras montadas de lado ou invertidas.

3. Métricas (mAP@0.5, precisão, revocação, F1 por classe)

Validação real (`model.val()`, Ultralytics, GPU, imgsz 640) do modelo SH17 no **conjunto de teste** (810 imagens, nunca usadas em treino nem validação):

EPI nosso	Classe SH17	Precisão	Revocação	F1	mAP@0.5	mAP@0.5:0.95
Capacete	helmet	0,810	0,512	0,628	0,669	0,441
Colete	safety-vest	0,810	0,433	0,564	0,490	0,323
Luvas	gloves	0,678	0,527	0,593	0,570	0,351
Óculos	glasses	0,712	0,678	0,694	0,696	0,411
Máscara	face-mask	0,837	0,588	0,691	0,696	0,472
Calçado	shoes	0,745	0,570	0,646	0,615	0,332
Protetor auricular	ear-acessorio	0,654	0,235	0,346	0,244	0,151
Agregado (17 classes do SH17)	—	0,733	0,588	—	0,621	0,414

Leitura honesta: o **protetor auricular** é o item mais fraco — só 17 instâncias no conjunto de teste, a classe mais rara do dataset, revocação de 0,235. Óculos e máscara têm o melhor desempenho. Nenhuma classe atinge a meta sugerida de $\text{mAP@0.5} \geq 0,75$ — gap real, não escondido.

[ATENCAO] **Escopo da medição acima:** é o modelo SH17 **isolado**, no próprio conjunto de teste dele — não em imagens da planta real.

3.1 Ensemble completo (Vyra + SH17, fundidos por IoU), medido contra o mesmo teste

Rodando o `EnsemblePPEDetector` de produção (mesma config do `.env`: `YOLO_CONFIDENCE`, `imgsz` 960, exclusão de "person" nos extras) contra as mesmas 810 imagens de teste do SH17, com script próprio (IoU@0.5, AP estilo VOC2012, ponto de operação no melhor F1):

EPI nosso	Precisão	Revocação	F1	mAP@0.5	vs. SH17 sozinho (mAP@0.5)
Capacete	0,576	0,463	0,514	0,517	-0,152
Colete	0,651	0,467	0,544	0,461	-0,029
Luvas	0,568	0,571	0,569	0,507	-0,063
Óculos	0,807	0,695	0,747	0,667	-0,029 (precisão +0,095)
Máscara	0,944	0,600	0,734	0,651	-0,045 (precisão +0,107)
Calçado	0,769	0,581	0,662	0,572	-0,043
Protetor auricular	0,625	0,294	0,400	0,260	+0,016

Achado honesto, não escondido: o ensemble saiu **pior em mAP@0.5** que o SH17 sozinho na maioria das classes, medido *neste* teste — só o protetor auricular melhorou. Isso não é regressão do sistema: o conjunto de teste é do SH17, não do Vyra. O Vyra foi treinado em outro dataset, com caixas calibradas de forma diferente; quando os dois modelos discordam e a caixa do Vyra "vence" a fusão por ter confiança maior, ela às vezes substitui uma caixa do SH17 mais bem ajustada ao gabarito do SH17 por uma que bate pior — penalizando o IoU e, com ele, o mAP. Esse mesmo efeito explica

por que a **precisão** sobe bastante em óculos e máscara (0,71->0,81 e 0,84->0,94): nesses casos o Vyra reduz falso positivo real, só que o ganho não aparece no mAP porque o gabarito de referência continua sendo o do SH17. Em outras palavras: **este número mede mal a contribuição real do Vyra**, porque o terreno de teste não é o dele — a métrica correta para o Vyra exigiria um conjunto de teste próprio do Vyra ou anotado pela equipe, que continua sendo o próximo passo declarado.

3.2 Confiabilidade do detector de PESSOA (pré-requisito de todo o resto)

O EPI e a pose só valem alguma coisa se o sistema achar a pessoa primeiro. A detecção de pessoa roda **separada** do EPI: como o Vyra sozinho não cobre bem várias pessoas na mesma cena, o sistema usa um segundo modelo dedicado — **YOLOv8n padrão (pré-treinado no COCO)** — só para a classe pessoa (`MULTI_PERSON_DETECTION=true`). Medido com a mesma metodologia (IoU@0.5, AP estilo VOC2012) no conjunto de teste do SH17:

Métrica	Valor
mAP@0.5	0,740
Precisão (melhor ponto)	0,759
Revocação	0,698
F1	0,727

É a **melhor métrica de todo o sistema** — muito acima de qualquer classe de EPI — porque "pessoa" é o caso de uso mais maduro do YOLO (COCO tem milhões de exemplos), enquanto EPI é um domínio de nicho com dataset pequeno. Ressalva: o detector encontrou 4.015 candidatos a pessoa contra 1.536 marcados no gabarito do SH17 — parte dessa diferença é gente real ao fundo das fotos de canteiro de obra que o SH17 não rotulou (não é o "trabalhador principal" da imagem), então a precisão medida (0,759) provavelmente está **subestimada**.

- **FPS:** ~19,5 quadros/segundo com o pipeline completo, uma câmera, GPU (RTX). Cai com múltiplas câmeras simultâneas (ver relatório da Fase 4).

4. Matriz de confusão e análise de erros

A matriz de confusão do treino do SH17 (`F:\treino_sh17\runs\sh17_v1\weights\`) mostra maior confusão entre classes anatômicas próximas (ex.: "ear" vs. "ear-acessorio", "face" vs. "face-acessorio") — esperado, já que a diferença visual entre a parte do corpo nua e o acessório que a protege é sutil em imagens de baixa resolução ou ângulo desfavorável. Falso positivo mais notado em produção: o modelo nano anterior (substituído nesta fase) confundia mão nua com luva; corrigido trocando de modelo e ligando o piso de confiança por classe.

5. Inovações desta fase

- Ensemble de dois modelos (não um só), para cobrir classes que o principal detecta mal.
- Distinção correto/incorreto/ausente, não binária.
- Regra situacional: EPI exigido varia por câmera (ver Fase 3, modo portaria).
- Rotação de câmera e zona de risco configuráveis, sem exigir reinício do sistema.

6. Demonstração

Vídeo institucional (`docs/pitch/VisionEPI-institucional-90s.mp4`) e demonstração ao vivo mostram a detecção rodando contra webcam e contra câmeras reais da planta parceira (RTSP), com pessoas reais em tempo real.

7. Entregáveis desta fase

- [x] 5 EPIs mínimos detectados (na verdade, 7)
- [x] Diferenciação correto/incorreto/ausente
- [x] Demo funcional em vídeo/stream
- [x] Métricas reportadas por classe (mAP@0.5, precisão, revocação, F1)
- [x] Relatório técnico (este documento)
- [x] Declaração de dataset com licenças — ver §9 do [CONSOLIDADO.md](#)